# Klasik NLP Görevleri

- Buğrahan Budakoğlu, Berk Talha Aslan, Umut Türker, Mert Ali Alkan
- Token etiketinden metin üretimine altı görevin girdi, hedef ve hata akışı.
- Kaynak: Hugging Face LLM Course, Bölüm 7.

# Bu bölümde neyi öğreneceğiz

- Bir görevi model adından önce girdi ve hedefiyle tanımlayın.
- Sıra: token sınıflandırma, MLM, çeviri, özetleme, causal LM, QA.
- Her görevde doğru veriyi hazırlayıp çıktının neyi kanıtladığını sorgulayın.

# Üç mimarinin veri akışı

- Encoder: girdi dizisini bağlamsal temsile çevirir. Örnek: BERT ile NER, MLM ve extractive QA.
- Causal decoder: geçmiş önekten sonraki token dağılımını tahmin eder. Örnek: GPT-2.
- Encoder-decoder: kaynak temsiline bakarak ayrı bir hedef dizi üretir. Örnek: BART ile çeviri ve özetleme.

# Token sınıflandırmada etiket hizası

- Girdi: Ayşe Ankara şehrine gitti .
- Çıktı: Ayşe / B-PER, Ankara / B-LOC, diğerleri / O.
- Bir kelime birkaç alt kelimeye ayrılabilir. Etiketleri word_ids ile taşıyın.
- Özel token ve seçilmeyen alt kelime hedefleri: -100.

# Maskeli dil modellemede hedef özgün tokendır

- Girdi: Ayşe [MASK] şehrine gitti .
- Hedef: maskelenmeden önceki Ankara tokenı.
- Seçilmemiş konumlar loss dışında kalır; -100 girdi tokenını silmez.
- BERT iki yöndeki görünür bağlamı kullanır.

# Çeviri iki eşleşen diziyle öğrenilir

- Kaynak: I love books .
- Hedef: Ben kitapları seviyorum .
- Kaynak ve hedef token sayıları eşit olmak zorunda değildir.
- Yerel örnek: text_target ile hedef hazırlama, -100 dolgu, generate ile çıktı.

# Özet iddiası kaynakta desteklenmeli

- Belge: Ayşe Ankara şehrine gitti . Toplantı yarın yapılacak .
- Kısa hedef: Ayşe Ankara şehrine gitti .
- Örtüşme metriği, sayının veya olumsuzluğun doğru korunduğunu garanti etmez.
- Yerel model örneklerini ezberleyebilir; yeni belge başarısı ölçülmedi.

# Causal model geçmişten devam üretir

- Önek: Mert
- Gerçek yerel çıktı: Mert Sivas şehrine gitti .
- Bir konumun hedefi sonraki tokendır; gelecek hedefe erişim kapanır.
- GPT2LMHeadModel etiket kaydırmayı içeride yapar; iki kez kaydırmayın.

# QA cevap aralığını seçer

- Soru: Mert nereye gitti ?
- Bağlam: Mert Sivas şehrine gitti .
- Gerçek yerel cevap: Sivas. Karakter aralığı [5,10).
- Token başlangıç/bitiş hedeflerini offsetlerle eşleyin. Uzun bağlamı pencerelere ayırın.

# Altı küçük model gerçekten çalıştırıldı

- CPU, seed 7, bir katman, 32 boyut, görev başına 100 eğitim adımı.
- NER / MLM: BERT. Çeviri / özetleme: ayrı BART modelleri.
- Causal LM: GPT-2. QA: BERT başlangıç ve bitiş başlığı.
- İnternet ve pretrained ağırlık indirmeden çalışma; örnekler insan yazımı.

# Kayıp düştü, genelleme ölçülmedi

- Token sınıflandırma: 1.0724 > 0.0003
- Maskeli dil modelleme: 3.8498 > 0.0029
- Çeviri: 3.8142 > 0.0019
- Özetleme: 3.7845 > 0.0017
- Nedensel dil modelleme: 3.8720 > 0.2326
- Soru yanıtlama: 2.5081 > 0.0001

# Hedef dışlamayı bozup geri alın

- Normal labels: [-100, 1, -100, 2, -100]. Aktif hedef: 2.
- Bozuk labels: [0, 1, -100, 2, 0]. Aktif hedef: 4.
- Düzeltme: özel hedefleri yeniden -100 yapın. Aktif hedef tekrar 2.
- Uniform logits ile üç ortalama loss da 1.098612; kayıp artışı iddia edilmez.

# Cevap ilk pencerede kaybolabilir

- Uzun bağlamın sonundaki Sivas cevabı: karakter aralığı [215,220).
- max_length=16 ile ilk pencerede cevap yok.
- Aynı girdi, stride=4: 8 pencere; son 2 pencerede cevap var.
- Gerçek fast tokenizer deneyi; model cevabının doğruluğunu ayrıca ölçmek gerekir.

# Alt kelime ve çıktı denetimini ayırın

- WordPiece: Ankaralı, Ankara ve ##lı parçalarına ayrıldı; 2 kelime etiketi 5 tokena hizalandı.
- Eksik iki nokta: ast.parse ile SyntaxError; düzeltince parse_ok.
- gönderme yerine gönder: sözcük örtüşmesi 5/6 kaldı, anlam tersine döndü.
- Ayrıştırma işlevsel doğruluk değildir. Basit sözcük oranı BLEU/ROUGE değildir.

Q01 · 20 SANİYE

# Sınıf sorusu 1

- Ayşe Ankara'ya gitti cümlesinde kişi ve yer buluyoruz. Uygun çıktı hangisidir?
- A: Cümle olumlu / olumsuz. B: Ayşe kişi, Ankara yer.
- C: Cümlenin Fransızcası. D: Bir sonraki kelime.
- Önce düşünün. Cevapları 18. sayfada birlikte açacağız.

Q04 · 20 SANİYE

# Sınıf sorusu 2

- Referansla ROUGE örtüşmesi yüksek. Hangi sonuç tek başına çıkarılamaz?
- A: Referansla karşılaştırıldı. B: Örtüşme birimlerinde benzerlik var.
- C: Protokol metin benzerliği ölçer. D: Her iddia kesin doğrudur.
- İpucu: Tek bir olumsuzluk sözcüğü anlamı nasıl değiştirir?

# Sınıf sorusu 3

- -100 yerine O=0 verildiğinde aktif hedef sayısı neden 2'den 4'e çıktı?
- Hatanın nedenini, en küçük düzeltmeyi ve yeniden testini söyleyin.
- İpucu: Yok sayılan hedef ile gerçek bir sınıfın farkı ne?
- Puanlama: ayrım 1, iki özel hedefi gösterme 1, geri alma ve test 1.

# Cevaplar ve gerekçeleri

- Q01: B. NER varlık konumlarını ve türlerini belirtir.
- Q04: D. Örtüşme, bütün iddiaların doğruluğunu kanıtlamaz.
- Q10: O=0 gerçek sınıf olduğu için iki özel konum da hedef oldu. -100 geri verilip hedef sayısı ve gradyan konumları sınanır.
- Tam soru dosyası: 13 kaynak uyarlaması, 3 ek soru, 12 ekip sorusu.

# Kaynaklar ve deneyin sınırları

- Hugging Face LLM Course: Bölüm 7, 1-9. Resmî quiz kaynak sürümü soru dosyasında kayıtlı.
- Gerçek koşum: Python 3.12.14, PyTorch 2.9.0+cpu, Transformers 4.57.1, Tokenizers 0.22.1.
- Pretrained ince ayar, bağımsız test, BLEU/ROUGE ve modelde prompt injection deneyi yapılmadı.
- Teslim: çeviri, PDF sunum, çalışan uygulama, soru-cevap, red-team raporu.